Classification d'images médicales

Cas d'étude : Détection de pneumonie sur radiographies thoraciques

F. DERRAZ

17 mars 2026

Plan

1. Contexte et problématique
2. Dataset Kaggle
3. Méthodologie
4. Modèle CNN
5. Protocole expérimental
6. Évaluation et interprétation
7. Planification et livrables
8. Extensions possibles
9. Conclusion

Contexte

- L'imagerie médicale génère un volume important de données : radiographies, IRM, scanners, etc.
- Les **CNN (Convolutional Neural Networks)** sont particulièrement adaptés à l'analyse automatique d'images.
- En contexte médical, l'objectif n'est pas de remplacer le médecin, mais de proposer un **outil d'aide à la décision**.
- Les plateformes comme **Kaggle** permettent de construire rapidement un projet reproductible à partir de datasets publics.

Cas d'étude retenu : classification binaire *Normal* vs *Pneumonia* sur des radiographies thoraciques.

Problématique

Question de départ :

Problème

Peut-on développer, en 10 jours, un pipeline CNN capable de distinguer des radiographies thoraciques normales de celles présentant une pneumonie, avec des performances cohérentes et une interprétation visuelle minimale ?

Contraintes du projet court :

- temps limité pour les expérimentations ;
- qualité variable des images ;
- déséquilibre possible entre classes ;
- risque de sur-apprentissage ;
- besoin d'une restitution claire et reproductible.

Objectifs du projet

1. Mettre en place un pipeline simple et reproductible de traitement d'images médicales.
2. Concevoir et entraîner un **CNN baseline** pour la classification binaire.
3. Évaluer le modèle avec des métriques adaptées : Accuracy, Recall, F1-score, AUC.
4. Analyser les erreurs à l'aide d'une matrice de confusion.
5. Ajouter, si le temps le permet, une interprétation visuelle de type **Grad-CAM**.

Livrables visés en 10 jours :

- notebook(s) Python reproductible(s),
- modèle baseline entraîné,
- figures d'évaluation,
- support de présentation,
- courte discussion critique des limites.

Dataset retenu

Dataset : `Chest X-Ray Images (Pneumonia)`

- Type de données : **images médicales** (radiographies thoraciques).
- Tâche : **classification binaire** (*NORMAL* vs *PNEUMONIA*).
- Intérêt pédagogique :
  - cas réel de vision médicale,
  - pipeline CNN accessible,
  - possibilité de démarrer vite avec une baseline robuste.

Point méthodologique

Avant tout entraînement, il faut vérifier la structure des dossiers, la répartition train/validation/test, l'équilibre des classes, la qualité des labels et l'absence de fuite de données.

Structure attendue des données

Organisation typique du dataset

```
dataset/
 train/
   NORMAL/
   PNEUMONIA/
 val/
   NORMAL/
   PNEUMONIA/
 test/
   NORMAL/
   PNEUMONIA/
```

Vérifications essentielles :

- nombre d'images par classe ;
- dimensions et formats ;
- images corrompues ;

Pipeline global du projet

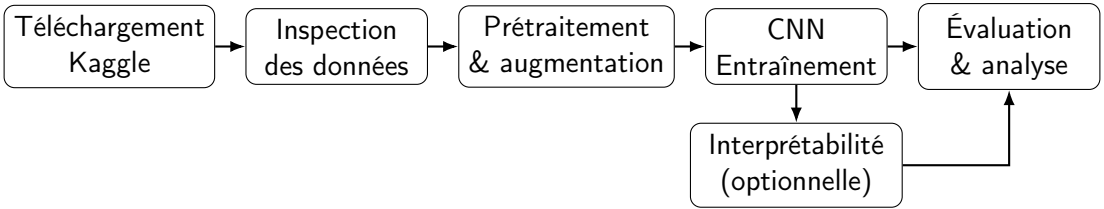

- Dans un projet sur 10 jours, on privilégie un **CNN simple et maîtrisé**.
- Les modèles plus complexes seront considérés comme des extensions.

Prétraitement des images

- Chargement en tenseurs avec `PyTorch` ou `TensorFlow`.
- Redimensionnement, par exemple en 224×224.
- Normalisation des intensités.
- Conversion éventuelle en 3 canaux pour un futur transfert d'apprentissage.

Prétraitements recommandés

- **Resize**,
- **Normalize**,
- visualisation d'un batch avant entraînement.

Attention

En imagerie médicale, éviter les transformations qui modifient le sens clinique de l'image.

Augmentation de données

- Objectif : améliorer la généralisation et limiter l'overfitting.
- Exemples raisonnables :
  - légère rotation ($\pm 5^\circ$ à $\pm 10^\circ$),
  - translation faible,
  - zoom léger,
  - faible variation de contraste/luminosité.
- L'augmentation ne s'applique qu'au **train set**.

Bonnes pratiques :

- pas d'augmentation sur validation/test ;
- protocole identique pour comparer les essais.

Architecture CNN baseline

Architecture proposée :

- Bloc 1 : Conv(32) + ReLU + MaxPool
- Bloc 2 : Conv(64) + ReLU + MaxPool
- Bloc 3 : Conv(128) + ReLU + MaxPool
- Flatten
- Dense(128) + Dropout
- Dense(1) + Sigmoid

Pourquoi une baseline ?

- elle est plus rapide à implémenter ;
- elle facilite le diagnostic des problèmes de données ;
- elle fournit un point de comparaison clair.

Schéma conceptuel du CNN

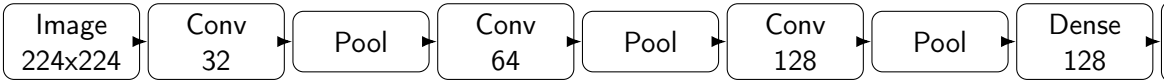

Sortie : probabilité $\hat{y} \in [0, 1]$ d'appartenance à la classe *PNEUMONIA*.

Fonction de coût et optimisation

Perte binaire :

$$\mathcal{L}_{BCE} = -\frac{1}{N}\sum_{i=1}^{N}\Big(y_i \log(\hat{y}_i) + (1-y_i)\log(1-\hat{y}_i)\Big)$$

Optimisation :

- Adam, avec $\eta = 10^{-3}$ comme point de départ ;
- réduction du taux d'apprentissage si besoin.

Régularisation :

- Dropout,
- Early stopping,
- weight decay,
- pondération des classes si nécessaire.

Protocole d'entraînement

- Taille image : 224×224
- Batch size : 16 ou 32
- Nombre d'époques : 10 à 20
- Optimiseur : Adam
- Learning rate initial : 10^{-3}
- Perte : Binary Cross-Entropy

Suivi minimal à produire

- loss train / validation,
- accuracy train / validation,
- matrice de confusion finale,
- éventuellement AUC.

Gestion des risques expérimentaux

- **Overfitting** : performance train trop supérieure à validation.
- **Data leakage** : fuite entre ensembles.
- **Déséquilibre** : accuracy parfois trompeuse.
- **Seuil de décision** : 0.5 n'est pas forcément optimal.

Principe

Sur un cas médical, la **sensibilité** doit être analysée avec attention afin de limiter les faux négatifs.

Métriques d'évaluation

À partir de la matrice de confusion :

- Accuracy $= \dfrac{TP + TN}{TP + TN + FP + FN}$
- Precision $= \dfrac{TP}{TP + FP}$
- Recall $= \dfrac{TP}{TP + FN}$
- Spécificité $= \dfrac{TN}{TN + FP}$
- F1-score $= 2 \cdot \dfrac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$

Compléments utiles :

- courbe ROC et AUC ;
- courbe précision-rappel si déséquilibre.

Matrice de confusion (gabarit)

	Prédiction	
Réel	Négatif	Positif
Négatif	TN = [À compléter : ...]	FP = [À compléter : ...]
Positif	FN = [À compléter : ...]	TP = [À compléter : ...]

- analyser les faux négatifs ;
- visualiser quelques erreurs significatives ;
- commenter les limites du modèle.

Interprétabilité (si le temps le permet)

Objectif :

- augmenter la confiance dans le comportement du modèle ;
- vérifier que le CNN se concentre sur des zones pertinentes.

Méthode proposée : Grad-CAM

- production d'une heatmap ;
- mise en évidence des régions influençant la prédiction.

Important

Dans un projet de 10 jours, Grad-CAM constitue une extension pertinente mais non indispensable pour valider la baseline.

Plan de travail sur 10 jours

Jour	Activités
J1	Cadrage du projet, installation de l'environnement, téléchargement du dataset, vérification de l'arborescence
J2	Exploration des données, comptage par classes, visualisation d'exemples, détection d'images corrompues
J3	Mise en place du pipeline de chargement, resize, normalisation, premiers batchs de contrôle
J4	Implémentation du CNN baseline et préparation de la boucle d'entraînement
J5	Premier entraînement complet, sauvegarde du modèle, observation des courbes train/validation
J6	Ajustements : batch size, learning rate, dropout, augmentation légère
J7	Second entraînement et comparaison des résultats avec la baseline initiale
J8	Évaluation finale : matrice de confusion, accuracy, recall, F1-score, AUC
J9	Analyse qualitative des erreurs, visualisations, ajout éventuel de

Livrables attendus en 10 jours

1. **Code source fonctionnel** :
   - exploration,
   - entraînement,
   - évaluation.
2. **Modèle baseline entraîné** (`.pt` ou `.h5`).
3. **Résultats expérimentaux** :
   - courbes,
   - matrice de confusion,
   - métriques principales.
4. **Présentation finale** et/ou mini-rapport technique.

Extensions possibles si le planning le permet

- transfert d'apprentissage : ResNet18, DenseNet121, EfficientNet ;
- comparaison baseline vs modèle pré-entraîné ;
- optimisation du seuil de décision ;
- Grad-CAM ou Grad-CAM++ ;
- mini-interface de démonstration sous Streamlit.

Priorité

Dans un projet de 10 jours, la priorité reste un pipeline propre, reproductible et bien évalué.

Ouverture vers d'autres datasets médicaux

Autres pistes de projets CNN en imagerie médicale :

- IRM cérébrale : classification de tumeurs ;
- détection de rétinopathie ;
- classification dermatologique.

Conseil

Commencer par une tâche binaire bien maîtrisée avant de passer à des tâches multi-classes ou à la segmentation.

Conclusion

- Ce projet permet de réaliser, en 10 jours, un pipeline complet de **Deep Learning appliqué à l'imagerie médicale**.
- Le dataset **Chest X-Ray (Pneumonia)** constitue un bon support pour construire une baseline rapide et pertinente.
- La réussite du projet repose sur un bon équilibre entre :
  - préparation des données,
  - rigueur expérimentale,
  - interprétation critique des résultats.
- Les extensions comme Grad-CAM ou le transfert d'apprentissage sont intéressantes, mais restent secondaires dans ce format court.

Merci pour votre attention

Annexe – Environnement Python

Librairies recommandées :

- `python >= 3.10`
- `torch`, `torchvision`
- `numpy`, `pandas`
- `matplotlib`, `scikit-learn`
- `opencv-python` (optionnel)
- `grad-cam` (optionnel)

Commande d'installation :

```
pip install torch torchvision numpy pandas matplotlib scikit-learn
```

Annexe – Arborescence de projet

```
medical-cnn-project/
 data/
    chest_xray/
 notebooks/
    01_eda.ipynb
    02_training_cnn.ipynb
    03_evaluation.ipynb
 src/
    dataset.py
    model.py
    train.py
    eval.py
 outputs/
    figures/
    checkpoints/
    reports/
 requirements.txt
 README.md
```

Références / Sources de données

- Kaggle – *Chest X-Ray Images (Pneumonia)*.
- Y. LeCun, Y. Bengio, Y. Hinton, *Deep Learning*, Nature, 2015.
- Articles et revues en Deep Learning pour l'imagerie médicale.

Note : compléter la bibliographie selon le niveau attendu du cours.